




MATERIAL DE CÁTEDRA-TEMA 1

ESTADÍSTICA INFERENCIAL

PARAMÉTRICA DE UNA POBLACIÓN



CARRERAS:

- Llic. en Sistema
- Prof. en Computación
- Analista en sistema

DOCENTES:

- Adjunto: Esp. Rolón Esteban Eduardo
- JTP : Matías Corvo
- JTP : Florencia Puente

MATERIAL TEÓRICO Y TRABAJOS

UNIDAD III : 1º PARTE-ESTADÍSTICA INFERENCIAL

- 1) INTRODUCCIÓN (pag.2)
- 2) CONCEPTOS FUNDAMENTALES DE LA INFERENCIA.....(pag.3)
- 3) DISTRIBUCIONES DE MUESTREO..... (pag.6)
- 4) ESTIMACIONES (pag.8)
- 5) TAMAÑO DE MUESTRA.....(pag.11)

1) INTRODUCCIÓN

La **estadística inferencial** tiene como fin obtener conclusiones acerca de parámetros poblacionales y para ello utiliza como medios, los estimadores (estadísticos) sus distribuciones en

el muestreo de probabilidad y diferentes conceptos tales como Teorema del límite central, error estándar, coeficiente de confianza y significancia y p-valor entre otros.

Generalmente existe una imposibilidad física de obtener datos de todos los elementos de la población; y en el caso de ser posible, el costo económico de estudiarlos es muy alto.

En este sentido por ejemplo en el Censo de Población y Vivienda en Argentina que se realiza cada diez años se contrata todo un equipo en cada localidad y provincia. Es importante recordar los tipos de variables según su caracterización (cuantitativa y cualitativa).

De esta manera se obtienen parámetros tales como la media poblacional (μ) de habitantes por hogar, la proporción (p) de hogares bajo la línea de la pobreza en Argentina, Cantidad total de habitantes por provincia (T), desvío estándar poblacional (σ) de ingresos por hogar entre otros.

El parámetro proporción poblacional, especialmente para variables cualitativas se define como el cociente (división) entre la cantidad de individuos con una característica de interés sobre el total de la población. Simbólicamente: $p = \frac{x}{N}$




figura 1

En la figura 1 se puede analizar la diferencia entre parámetro y estadístico ya que la “**P**: Proporción de unidades de análisis de color rojo de la población” se calcula: $p = 9 / 58 = 0,16$
El **estadístico o estimador** se presenta así y calcula así: $\hat{p} = 2/10 = 0,20$

“ $\hat{p}_1$ = Proporción de unidades de análisis de color rojo de la muestra ”

Ahora bien a partir de los estadísticos tales como **medias muestrales y proporciones muestrales** semestralmente con una encuesta de hogares con un muestreo probabilísticos en todo la Argentina se obtienen estadísticos muy confiables y se puede cuantificar el grado de probabilidad de haber tomado un resultado o una decisión incorrecta. Se entiende como una **muestra aleatoria** cuando es seleccionada de manera que cada elemento o persona en la población que se estudia tiene una probabilidad conocida de quedar incluido en la muestra.

2) CONCEPTOS FUNDAMENTALES DE LA INFERENCIA

Población: Es el conjunto de todos los elementos o unidades de análisis sobre los cuales se observa una o más características de Interés. Frecuentemente se alude a ella como población objetivo, en razón de que sobre ella recae el objetivo o el interés del estudio.

Variable: Característica o propiedad de una unidad de análisis que puede ser observada o medida o comparada por medio de un número, atributo o categoría. En el cuadro se las clasifica:

Cuadro n°1	SEGÚN VALORES	SUB CLASIFICACIÓN	EJEMPLOS
VARIABLES CUANTITATIVAS O NUMÉRICAS	Continuas		Y_1 : Peso ; Y_2 : altura X_1 : longitud X_1 : área afectada Y_2 : dosis aplicada {cm ³ o ml} X : $\bar{x}$: media muestral (aleatoria) Z : $\hat{p}$: proporción muestral (aleatoria)
	Discretas		X : cantidad de hijos Y : cantidad de hojas Z : cantidad de deformaciones
VARIABLES CUANTITATIVAS	Nominal (sin orden)	Dicotómica (dos valores)	X : Sexo = {F ; M} Y : Preñez : {SI ; No} Z : Enfermedad { 0 ; 1 }
		Politómica : (múltiples valores)	X : Tipo.de.enfermedad= {Diabetes , hepatitis , HIV .. } Y : Grupo_Sanguíneo{ A+; A-, AB, B+, B - } Z : Lugar de residencia
	Ordinal (con orden)		X : Nivel de glucosa = {Bajo, medio, alto} Y : Grupo_peso{ delgado; normal, sobrepeso } Z : Frec.de uso glifosato = {poco, algunas veces , bastante , mucho}


Hipótesis estadísticas: Proposición lógica o afirmación acerca de características o propiedades de la población que a partir de datos del investigador del muestreo puede ser puesta a prueba para establecer si se rechaza o no (Verdadera o Falsa).

Algunos ejemplos: a) La media de peso de un recién nacido en el hospital materno Neonatal de Posadas es menor o igual a 3200 gr. Simbólicamente: $H_0: \mu \leq 3200$ gr

b) El porcentaje de madres de niños con malformaciones que consumieron alcohol antes del parto es mayor al 60 %. Simbólicamente: $H_1 : p > 0,60$

Hipótesis nula: Hipótesis considerada como verdadera para ser puesta a prueba con las evidencias y los valores límites del estadístico de prueba. Presenta zonas de rechazo y no rechazo.

Hipótesis alternativa: Generalmente es lo que el investigador desea aceptar y es el complemento de la nula.



Estadístico: Es una característica muestra numérica y, como tal, es una variable porque sus valores dependen de la muestra que salga seleccionada (piense que dada una población pueden extraerse muchas muestras diferentes). Cada valor del estadístico se obtiene como función de las observaciones de una muestra.

Por ejemplo, tiempo promedio de reacción de 10 individuos que fueron entrenados, o el porcentaje de consumidores entre 100 encuestados que manifestaron tener una actitud positiva frente al producto.

Variable tipificada (z) : Me indica la cantidad de veces que un valor determinada se ha alejado de la media o valor esperado se calcula : $z = \frac{x - \theta}{\sigma}$, por ejemplo si la media es 6,5, y el desvío estándar 0,5, se obtienen datos : $D = \{7 ; 6,5 ; 6 ; 8,5 ; 4,5 \dots\}$ al tipificarlos obtendríamos : Tipificados : $\{1 ; 0 ; -1 ; 2 ; -2 \dots\}$, donde las ventajas radican en que:


1º) La media es igual a 0 y la unidad de medida es el desvío estándar .

2º) Con los signos puedo saber si estoy por debajo o por encima de la media

3°) Mantienen la misma distribución de frecuencia que la variable original.

4°) Y finalmente no tiene unidades de medida es decir es un valor relativo

Significancia (α): El valor de alfa, también denominado **nivel de significación**, es definido por el investigador antes de recoger los datos, y la costumbre es hacer $\alpha=0.05$ o $\alpha=0.01$, indica el umbral o límite de riesgo o probabilidad de rechazar la hipótesis nula cuando esta es verdadera. En algunas ocasiones se divide por dos para hallar los límites tipificado y se utiliza una tabla o aplicación, ver los ejemplos de las siguientes funciones de densidades normales:



Confianza ($1 - \alpha$): Se calcula con la diferencia entre 1 y el nivel de significancia, si $\alpha=0,05$ la confianza del investigador en tomar una correcta decisión será del $1 - 0,05 = 0,95$ (95%).

P-valor(p): Es el valor más importante y más utilizados en las investigaciones y publicaciones científicas ya que te permite cuantificar tu riesgo de rechazar una hipótesis cuando esta es considerada verdadera. Si el p-valor $< 0,05$ por convención se considera un umbral significativo para rechazar la hipótesis nula y aceptar la alternativa.

Por ejemplo: Si mi hipótesis es que la media peso de un tipo de pez es igual o menor a 54 gr si obtengo luego de las pruebas estadística un p-valor = 0,02 puedo rechazarla y aceptar que el peso medio es mayor que 54 gr.

3) DISTRIBUCIONES DE MUESTREO

3.1) Distribuciones de muestreo de las medias muestrales

La distribución de muestreo de medias muestrales es la distribución de probabilidad de todas la medias muestrales posibles de un tamaño de muestra dado, seleccionadas de una población, y la probabilidad de ocurrencia asociada con cada media muestral.

Veamos un ejemplo práctico: En un laboratorio hay cinco ejemplares de una especie animal cuyos pesos se ven en la siguiente tabla

casos	Pesos (Kg)
1	22
2	26
3	30
4	26
5	22

Si se seleccionan al azar dos animales, ¿cuántas muestras diferentes son posibles? Serían un número combinatorio de 5 tomado de a 2 que da 10 muestras.

Si las organizo puedo construir una distribución de muestreo de las medias muestrales con sus probabilidades de ocurrencia.

Media Muestral	Frecuencia	Frecuencia relativa
22	1	1/10
24	4	4/10
26	3	3/10
28	2	2/10


Calculando la media de las medias muestrales y comparándola con la media poblacional:

media de las medias muestrales = $[(22)(1) + (24)(4) + (26)(3) + (28)(2)]/10 = 25.2$

Siendo que la media poblacional es $(22+26+30+26+22)/5 = 25.2$

Obsérvese que la media de las medias muestrales es igual a la media poblacional.

En el caso de una población más grande también se cumple esta propiedad y si las muestras son mayores de 30 se obtiene una población de medias muestrales las mismas cumplen con el teorema de límite central que repasaremos en el siguiente tema.



3.2) Teorema del Límite Central

Para una población con media μ y desvío estándar σ , la distribución de muestreo de las medias de todas las muestras posibles de tamaño n obtenidas de una población tendrá una distribución normal aproximada —con la media de la distribución de muestreo igual a μ y el desvío a igual

a $\frac{\sigma}{\sqrt{n}}$, si se supone que el tamaño de la muestra es suficientemente grande ($n \geq 30$)


Simbólicamente : $\bar{x} \sim N \left(\mu_{\bar{x}} = \mu ; \frac{\sigma}{\sqrt{n}} \right)$

3.3) Distribución muestral de las proporciones muestrales

De la misma manera que en el estudio de las medias muestrales se estableció que se forma una distribución normal alrededor de la media de la población, conociendo el parámetro proporción poblacional (p) si se extrajeran muestras de tamaño n lo suficientemente grande se encontraría que estas proporciones tienen una distribución en el muestreo aproximadamente normal en torno a la proporción poblacional (p), por lo cual se utilizará la función de distribución normal estándar como herramienta para la estimación por intervalos y pruebas de hipótesis. Simbólicamente podemos decir en base a experiencias empíricas que:

$$\hat{p} \sim N \left(\mu_p = p ; \sigma_p = \sqrt{\frac{p \cdot q}{n}} \right)$$

Esquemáticamente tendríamos una población o conjunto de proporciones muestrales al realizar varios muestreos aleatorios, como se ve en el siguiente gráfico:



En conclusión tanto la media de las proporciones muestrales como la media de las medias muestrales tienden a sus parámetros correspondientes y poseen una distribución en el muestreo que se aproxima a una curva de distribución de probabilidad normal ..

4) ESTIMACIONES

4.1) Estimaciones puntuales

Una estimación puntual es un valor (punto) que se usa para estimar un parámetro de la población. Ejemplos de estimaciones puntuales son media muestral $\bar{x}$, desviación estándar muestral (s), variancia muestral, proporción de la muestra(p), entre otros.

4.2) Estimaciones de intervalo de la media

Una estimación de intervalo establece la amplitud en la que quizá se encuentre un parámetro poblacional. El intervalo dentro del cual se espera que esté un parámetro poblacional se llama intervalo de confianza. Los dos intervalos de confianza que más se usan son 95% y 99%.

Interpretación y demostración del intervalo de confianza: Si tomamos en cuenta una muestra de $n \geq 30$ sabemos por TLC que las medias muestrales se distribuyen normalmente por lo tanto aproximadamente a 2 desvíos estándar se encuentra el 95% de las medias, dicho de otra manera hay un 95% de confianza que una media muestral no se aleje más que dos desvíos hacia la izquierda y hacia la derecha.

Si aceptamos esto realizando y nos interesa la media de la población podríamos despejarla de la siguiente manera:

$$P\left(\mu - 2 \cdot \frac{\sigma}{\sqrt{n}} < \bar{x} < \mu + 2 \cdot \frac{\sigma}{\sqrt{n}}\right) \approx 0,95 \quad ; \text{ (si en cada termino aplicamos } -\mu - \bar{x})$$

$$P\left(-2 \cdot \frac{\sigma}{\sqrt{n}} - \bar{x} < \bar{x} - \mu - \bar{x} < 2 \cdot \frac{\sigma}{\sqrt{n}} - \bar{x}\right) \approx 0,95 \text{ (logramos cancelar la media muestral)}$$

$$P\left(-2 \cdot \frac{\sigma}{\sqrt{n}} - \bar{x} < -\mu < 2 \cdot \frac{\sigma}{\sqrt{n}} - \bar{x}\right) \approx 0,95 \text{ (multiplicamos por -1 cambia inecuación)}$$

$$P\left(\bar{x} + 2 \cdot \frac{\sigma}{\sqrt{n}} > \mu > \bar{x} - 2 \cdot \frac{\sigma}{\sqrt{n}}\right) \approx 0,95 \text{ (reordenamos inecuación)}$$

$$P\left(\bar{x} - 2 \cdot \frac{\sigma}{\sqrt{n}} < \mu < \bar{x} + 2 \cdot \frac{\sigma}{\sqrt{n}}\right) \approx 0,95 \text{ (finalmente nos queda)}$$

Los IC de 95% Y 99 % usando la distribución normal estándar (apps, tablas o software) buscando el valor de z positiva que determina la probabilidad $\alpha/2$

$$IC(1-\alpha) = \bar{x} \pm z \cdot \frac{\sigma}{\sqrt{n}}$$


$$IC(95\%) = \bar{x} \pm 1,96 \cdot \frac{\sigma}{\sqrt{n}}$$

$$IC(99\%) = \bar{x} \pm 2,58 \cdot \frac{\sigma}{\sqrt{n}}$$

Un intervalo de confianza de 95% significa que cerca de 95% de los intervalos similares contendrán el parámetro que se quiere estimar, o 95% de las medias muestrales para un tamaño de muestra dado estarán dentro de 1.96 desviaciones estándar de la media poblacional hipotética. Para el intervalo de confianza de 99%, un 99% de las medias muestrales para un tamaño de muestra dado estará dentro de 2.58 desviaciones estándar de la media poblacional hipotética.

Si $n < 30$, no se conoce la varianza poblacional y se tiene una variable aproximadamente con distribución normal se utiliza una distribución llamada T-Student (z mejorada) que incluye también el tamaño de la muestra menos 1 que se denomina grados de libertad ($v=n-1$), más adelante profundizaremos el tema :

$$IC(1-\alpha) = \bar{x} \pm t_{(v, 1-\frac{\alpha}{2})} \cdot \frac{\hat{s}}{\sqrt{n}}$$



Por ejemplo se midió el tiempo de reacción que tiene un fármaco sobre 16 pacientes obteniéndose una media de 15,5 horas y un desvío estándar de 1,5 horas con una distribución aproximadamente normal de la población, determinar el intervalo de confianza de 95% y 99% .

Datos : $\bar{x} = 15,4$; $s = 1,5$; $x \sim Normal$; *grados de libertad* : $v = 16 - 1 = 15$

sabemos que $\alpha/2=0,05/2=0,025$, $1- \alpha/2 = 0,975$ y por tabla o aplicación $t_{(15, 1-\alpha/2)} =$

$$IC(95\%)= 15,4 \pm 2,13 \cdot \frac{1,5}{\sqrt{16}} = [14,60; 16,20]$$

Interpretación: Con un 95% de confianza afirmamos que la media de tiempo de reacción del fármaco está entre 14,60 y 16,40 horas .

4.3) Intervalo de confianza para una proporcional de población

Conociendo que la proporción muestral se distribuye aproximadamente normal si $n > 30$ se puede calcular el desvío estándar, también llamado error estándar así :

Siendo “p” proporción poblacional de éxito y (1-p) la proporción de fracaso q , en el caso que se no se cuente con ellas se usa Las proporciones muestrales $\hat{p}$ y $\hat{q}$

$$\sigma_{\bar{p}} = \sqrt{\frac{p(1-p)}{n}}$$

Interpretación y demostración del intervalo de confianza : Aceptando que aproximadamente el 95 % de las proporciones muestrales (muestras) está a no más de dos desvíos estándar de la proporción poblacional despejando nos queda:

$$P(\hat{p} - 2 \cdot \sqrt{\frac{p \cdot q}{n}} < \mu < \hat{p} + 2 \sqrt{\frac{p \cdot q}{n}} \approx 0,95 \text{ (resultado del despeje)}$$

Por lo cual se utiliza los valores de la distribución normal estándar z : $IC(95\%) = \hat{p} \pm z \sqrt{\frac{pq}{n}}$

, donde z representa el coeficiente de confianza , nos indica la cantidad de errores estándar que vamos a tomar para estimar la media poblacional .

Ejemplo: El Ministerio de Salud estudia la proporción de jóvenes que no trabajan ni estudian. Una muestra de 500 jóvenes estableció que 175 no tienen trabajo ni estudian en Argentina. Desarrolle un intervalo de confianza de 98% para la proporción de interés.

Datos: Aquí, $n=500$, $p=175/500=.35$ y $|z| = (0,02/2) = |z(0,01)|=2.33$ (tabla) ; entonces

$$IC \text{ de } 98\% \text{ es : } IC(98\%) = 0,35 \pm 2.33 \sqrt{\frac{0,35 \cdot 0,65}{500}} = 0,35 \pm 0,0497$$

4.4) Factor de corrección de población finita

Se dice que una población con una cota superior fija es finita.
Para una población finita, donde el número total de objetos es N y el tamaño de la muestra es n , se hace el siguiente ajuste a los errores estándar de las medias muestrales y a las proporciones:

Error estándar de las medias muestrales:

$$\sigma_{\bar{x}} = \frac{\sigma}{\sqrt{n}} \sqrt{\frac{N-n}{N-1}}$$

Error estándar de las proporciones de las muestras:

$$\sigma_p = \sqrt{\frac{P(1-P)}{n}} \cdot \sqrt{\frac{N-n}{N-1}}$$

5) TAMAÑO DE MUESTRA

5.1) Tamaño de la muestra para proporciones

Uno de los principales problemas de un investigador es establecer que tan grande debe ser su muestra para alcanzar los estándares de calidad que dicha investigación necesita. Para ello existen 3 factores que determinan el tamaño de una muestra, ninguno de ellos tiene una relación directa con el tamaño de la población. Los factores son:

RECORDAMOS : IC = Media +/- margen de error

$$IC = x + z \cdot \text{desvío} / \text{raíz}(n)$$

Despejando podemos encontrar n : tamaño

- 1) El grado de confianza elegido.
- 2) El error máximo permitido.
- 3) La variación en la población.

Si consideramos $E = z \cdot \frac{\sigma}{\sqrt{n}}$ al error máximo o la mitad de

la amplitud del intervalo realizando un despeje :

$$n = \frac{z^2 \cdot \sigma^2}{E^2}$$

La fórmula para determinar el tamaño de la muestra en el caso de una proporción es:

$$n = p(1-p) \left(\frac{Z}{E} \right)^2$$

donde p es la proporción estimada, basada en la experiencia o en un estudio piloto; z es el valor asociado con el nivel de confianza deseado; E es el error máximo que tolerará el investigador.

Ejemplo: Se desea estimar la proporción de niños que tienen un bajo peso al nacer con una estimación no mayor al 3% de la relación proporcional, ¿cuántos niños deberán evaluar si un premuestreo determinó una proporción del 0,30 con bajo peso y se establece un 95% de confianza?

$$n = (.30)(.70)(1.96/.03)^2 = 896.3733 \approx 897$$