

TEMA 1B: ESTADISTICA INFERENCIAL PARA COMPARAR DOS POBLACIONES

Temas centrales: DIFERENCIA DE PROPORCIONES Y DIFERENCIA DE MEDIAS

1) INTRODUCCIÓN Y REPASO

1.1) Retomando lo del tema anterior uno de los propósitos de la estadística inferencial es extraer conclusiones acerca de la naturaleza de una población, ahora bien en ocasiones se quiere **comparar dos poblaciones**, para ello se utilizará como parámetros : la diferencia de medias $\Delta\mu = (\mu_2 - \mu_1)$ y las proporciones muestrales $\Delta p = (p_2 - p_1)$.

En este sentido utilizaremos los correspondientes estimadores : $\Delta \hat{x} = (\bar{X}_1 - \bar{X}_2)$ y las proporciones muestrales $\Delta \hat{p} = (\hat{p}_1 - \hat{p}_2)$

El muestreo en ambas poblaciones debe ser probabilístico, el más utilizado es el muestreo aleatorio simple, en el que todos los elementos de la población tienen la misma probabilidad de ser extraídos e incluidos en la muestra.

Existen otros tipos de muestreo como el muestreo por conglomerados, sistemático y estratificado que también son válidos ya que son probabilísticos.

De la misma manera que en estadística 1 y el tema anterior cuando contamos con dos poblaciones, debemos estudiar a sus estimadores en cuanto a su distribución, valor más esperado $E(x)$ y desvío estándar (error estándar) , por lo cual la aplicación de los principios de la estadística inferencial deben hacerse en tres partes:

- 1) Las distribuciones muestrales
- 2) La estimación
- 3) El contraste de hipótesis.

Este apunte está organizado de manera que para cada caso, sean tratados los tres aspectos estadísticos pero antes de avanzar en lo que nos interesa la **comparación entre dos poblaciones** es crucial repasar los conceptos claves.

1.2) DISTRIBUCIONES MUESTRALES (GENERAL)

Si las muestras obtenidas de una población son aleatorias, no se espera que dos muestras aleatorias del mismo tamaño y tomadas de la misma población sean completamente parecidas; puede esperarse que cualquier estadístico, como por ejemplo la media muestral, calculado a partir de las medias en una muestra aleatoria, cambie su valor de una muestra a otra. Por ello, lo que se busca es estudiar la distribución de todos los valores posibles de un estadístico. Es decir, como los valores de un estadístico, tal como x , varían de una muestra aleatoria a otra, se le puede considerar como una *variable*

aleatoria con su correspondiente distribución de frecuencias. La distribución de frecuencias de un estadístico muestral se denomina **distribución muestral**.

En general, **la distribución muestral de un estadístico** es la de todos sus valores posibles calculados a partir de muestras del mismo tamaño.

Las distribuciones muestrales pueden construirse experimentalmente a partir de poblaciones finitas y discretas de la siguiente manera:

1. De una población finita de tamaño N , se extraen de manera aleatoria todas las muestras posibles de tamaño n .
2. Se calcula la estadística de interés para cada muestra.
3. Se lista en una columna los distintos valores de la estadística, y en otra columna las frecuencias correspondientes de cada valor observado.

Así, si se calcula la media muestral para cada muestra; la colección de todas estas medias muestrales recibe el nombre de distribución muestral de medias. Si hacemos lo mismo con las desviaciones estándares, la colección de todas estas desviaciones estándar muestrales se llama distribución muestral de la desviación estándar. Normalmente, para una distribución muestral, se tiene interés en conocer tres cosas: *media, varianza y forma funcional* (apariencia gráfica).

2) DIFERENCIA DE MEDIAS POBLACIONALES

2.1) DISTRIBUCIÓN MUESTRAL DE LA DIFERENCIA DE MEDIAS MUESTRAL

Con frecuencia, el interés se centra en dos poblaciones. Puede ser que un investigador desee saber algo acerca de las diferencias entre las medias de dos poblaciones. Para este y otros casos, el conocimiento acerca de la distribución muestral de la diferencia entre dos medias es muy útil.

Se tienen dos poblaciones distintas, la primera con media μ_1 y desviación estándar σ_1 , y la segunda con media μ_2 y desviación estándar σ_2 . Se elige una muestra aleatoria de tamaño n_1 de la primera población y una muestra independiente aleatoria de tamaño n_2 de la segunda población; se calcula la media muestral para cada muestra y la diferencia entre dichas medias.

La colección de todas esas diferencias junto con sus frecuencias, se llama distribución muestral de las diferencias entre medias o la distribución muestral del estadístico :

$$\Delta \hat{x} = (\bar{X}_1 - \bar{X}_2)$$

La distribución es aproximadamente normal para $n_1 \geq 30$ y $n_2 \geq 30$. Si las poblaciones son normales, entonces la distribución muestral de medias es normal sin importar los tamaños de las muestras. Sabemos que cuando n es grande, la distribución muestral de medias tendrá aproximadamente una distribución normal con una media igual a μ (la media de la población) y una desviación estándar de $\sigma/\sqrt{n}$.

Con esto podemos deducir que la media para esta distribución muestral de diferencia de medias es igual a la diferencia entre las medias reales de las poblaciones $\mu_1 - \mu_2$. La varianza es igual a $(\sigma_1^2/n_1) + (\sigma_2^2/n_2)$. Y el error estándar de la diferencia entre las medias muestrales es:

$$\sigma_{\bar{x}_1 - \bar{x}_2} = \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}$$

La fórmula que se utilizará para el cálculo de probabilidad del estadístico de diferencia de medias es:

$$z = \frac{(\bar{x}_1 - \bar{x}_2) - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}}$$

Este procedimiento es válido incluso cuando el tamaño de las muestras es diferente y cuando las varianzas tienen valores diferentes.


Ejemplo: En un estudio para comparar los pesos promedio de niños y niñas de sexto grado en una escuela primaria se usará una muestra aleatoria de 20 niños y otra de 25 niñas. Se sabe que tanto para niños como para niñas los pesos siguen una distribución normal. El promedio de los pesos de todos los niños de sexto grado de esa escuela es de 100 libras y su desviación estándar es de 14.142, mientras que el promedio de los pesos de todas las niñas del sexto grado de esa escuela es de 85 libras y su desviación estándar es de 12.247 libras. Si $\bar{x}_1$ representa el promedio de los pesos de 20 niños y $\bar{x}_2$ es el promedio de los pesos de una muestra de 25 niñas, encuentre la probabilidad de que el promedio de los pesos de los 20 niños sea al menos 20 libras más grande que el de las 25 niñas.

Solución: Datos:

$\mu_1 = 100$ libras $\mu_2 = 85$ libras , $\sigma_1 = 14.142$ libras , $\sigma_2 = 12.247$ libras

$n_1 = 20$ niños , $n_2 = 25$ niñas y $p(\bar{x}_1 - \bar{x}_2 > 20) = ?$

$$z = \frac{(\bar{x}_1 - \bar{x}_2) - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} = \frac{20 - (100 - 85)}{\sqrt{\frac{(14.142)^2}{20} + \frac{(12.247)^2}{25}}} = 1.25$$



Conclusión :

Por lo tanto, la probabilidad de que el promedio de los pesos de la muestra de niños sea al menos 20 libras más grande que el de la muestra de las niñas es 0.1056.

2.2) ESTIMACIÓN DE LA DIFERENCIA ENTRE DOS MEDIAS

En ciertos casos, se desea estimar la diferencia entre las medias de dos poblaciones. Teniendo dos poblaciones donde el carácter que estudiamos en ambas (X_1 y X_2) son v.a. distribuidas según leyes gaussianas, podemos realizar una estimación de la diferencia entre dos medias.

A partir de cada población se extrae una muestra aleatoria independiente y de los datos de cada una se calculan las medias muestrales $\bar{x}_1$ y $\bar{x}_2$. Sabemos que el estimador $\bar{x}_1 - \bar{x}_2$ proporciona una estimación insesgada de $\mu_1 - \mu_2$, que es la diferencia entre las medias de las poblaciones. La varianza del estimador es $(\sigma_1^2/n_1) + (\sigma_2^2/n_2)$.

Por tanto, para obtener una estimación puntual de $\mu_1 - \mu_2$, se seleccionan dos muestras aleatorias independientes que no tienen por qué ser necesariamente del mismo tamaño, una de cada población, de tamaño n_1 y n_2 , se calcula la diferencia $\bar{x}_1 - \bar{x}_2$, de las medias muestrales.

Intervalo para la diferencia de medias cuando se conoce la varianza:

Recordando a la distribución muestral de diferencia de medias:

$$Z = \frac{(\bar{x}_1 - \bar{x}_2) - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}}$$

Al despejar de esta ecuación $\mu_1 - \mu_2$ se tiene:

$$\mu_1 - \mu_2 = (\bar{x}_1 - \bar{x}_2) \pm Z \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}$$

En el caso en que se desconozcan las varianzas de la población y los tamaños de muestra sean mayores a 30 se podrá utilizar la varianza de la muestra como una estimación puntual.

Ejemplo: A un equipo de investigación le interesa conocer la diferencia entre las concentraciones de ácido úrico en pacientes con y sin mongolismo. En una hospital para el tratamiento del retardo mental, una muestra de 12 individuos con mongolismo proporciona una media de $\bar{x}_1 = 4.5 \text{ mg/100ml}$. En un hospital general se encontró que una muestra de 15 individuos normales de la misma edad y sexo presenta un nivel medio de $\bar{x}_2 = 3.4$. Si suponemos que las dos poblaciones de valores muestran una distribución normal y sus varianzas son iguales a 1, calcular el intervalo de confianza del 95% para $\mu_1 - \mu_2$.

Solución: Para una estimación puntual de $\mu_1 - \mu_2$ se utiliza $\bar{x}_1 - \bar{x}_2 = 4.5 - 3.4 = 1.1$. El coeficiente de confiabilidad correspondiente al .95, que se halla en la tabla normal, es 1.96. El error estándar es:

$$\sqrt{\frac{1}{12} + \frac{1}{15}} = 0.39, \text{ Por lo tanto el intervalo de confianza del 95\% } \left\{ \begin{array}{l} 1.1 \pm 1.96 (0.39) \\ 1.1 \pm 0.8 \\ (0.3 ; 1.9) \end{array} \right.$$

Interpretación: Se dice que se tiene una confianza del 95% de que la diferencia real $\mu_1 - \mu_2$, está entre 0.3 y 1.9 debido a que en muestreos repetidos el 95% de los intervalos construidos de esa manera incluiría la diferencia entre las medias reales.

2.2) INTERVALO PARA LA DIF. DE MEDIAS CUANDO SE DESCONOCE LA VARIANZA Y $n < 30$

Cuando se desconocen las varianzas de la población y se requiere estimar la diferencia entre las medias de dos poblaciones con un intervalo de confianza, se puede utilizar la distribución t para extraer el factor de confiabilidad, siempre que las poblaciones sean normales o supongamos que lo son.

a) Intervalo para la diferencia de medias homocedáticas(varianzas iguales):

Si suponemos que las varianzas de dos poblaciones son iguales, las dos varianzas de las muestras calculadas a partir de las muestras independientes pueden construirse como estimaciones de una sola cosa, la varianza común. Esta varianza se obtiene calculando el promedio ponderado de las dos varianzas de las muestras. Cada varianza de las muestras es ponderada en base a sus grados de libertad. La estimación conjunta se obtiene con la formula:

$$\hat{S}^2 = \frac{(n_1 - 1)\hat{S}_1^2 + (n_2 - 1)\hat{S}_2^2}{n_1 + n_2 - 2}$$

Donde se ha definido a $\hat{S}^2$ como la *cuasivarianza muestral ponderada* de $\hat{S}_1^2$ y $\hat{S}_2^2$. Las varianzas se desconocen, el intervalo se distribuye entonces como una t de Student con $n_1 + n_2 - 2$ grados de libertad

Si $1 - \alpha$ es el nivel de significación con el que deseamos establecer el intervalo para la diferencia de las dos medias, calculamos el valor $t_{n_1 + n_2 - 2, 1 - \alpha/2}$ que deja por encima de si $\alpha/2$ de la masa de probabilidad de $T_{n_1 + n_2 - 2}$. El

intervalo de confianza al nivel $1 - \alpha$ para la diferencia de esperanzas de dos poblaciones con la misma varianza (aunque esta sea desconocida) es:

$$\mu_1 - \mu_2 = (\bar{X}_1 - \bar{X}_2) \pm t_{n_1 + n_2 - 2, 1 - \alpha/2} \cdot \hat{S} \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}$$

Ejemplo: Se efectuaron estudios sobre la concentración media de amilasa en suero de una población sana. Las mediciones se efectuaron en una muestra de 15 individuos aparentemente saludables. La muestra proporcionó una media de 96 unidades/100ml y

una desviación estándar de 35 unidades/100ml. Se hicieron también las determinaciones de amilasa en el suero de 22 individuos hospitalizados que forman una muestra independiente. La media y la desviación estándar de esta muestra son 120 y 40 unidades/ml, respectivamente. La estimación puntual de $\mu_1 - \mu_2$ es de $120 - 96 = 24$. Se desea construir un intervalo de confianza para la diferencia entre las concentraciones medias de amilasa del suero en individuos aparentemente sanos y la media para los pacientes hospitalizados.

Solución: Suponemos que las dos poblaciones en estudio tienen una distribución normal y que sus varianzas son iguales. Primero, buscamos la estimación conjunta de la varianza común como sigue:

$$\hat{S}^2 = 14(35)^2 + 21(40)^2 / 15 + 22 - 2 = 1450$$

El intervalo de confianza del 95% para $\mu_1 - \mu_2$ es:

$$\begin{aligned} (120-96) \pm 2.0301 \sqrt{\frac{1450}{15} + \frac{1450}{22}} \\ 24 \pm (2.0301)(12.75) \\ 24 \pm 26 \\ (-2 ; 50) \end{aligned}$$

Se dice que se tiene un 95% de confianza de que la diferencia real $\mu_1 - \mu_2$ esta entre -2 y 50 ya que, al muestrear varias veces, el 95% de los intervalos así contruidos incluyen a $\mu_1 - \mu_2$.

Ejemplo: Queremos estudiar la influencia que puede tener el tabaco con el peso de los niños al nacer. Para ello se consideran dos grupos de mujeres embarazadas (unas que fuman un paquete al día y otras que no) y se obtienen los siguientes datos sobre el peso X , de sus hijos:

$$\left\{ \begin{array}{ll} \text{Madres fumadoras} & \rightarrow n_1 = 35 \text{ mujeres, } \bar{x}_1 = 3,6 \text{ Kg } \hat{S}_1 = 0,5 \text{ Kg} \\ \text{Madres no fumadoras} & \rightarrow n_2 = 27 \text{ mujeres, } \bar{x}_2 = 3,2 \text{ Kg } \hat{S}_2 = 0,8 \text{ Kg} \end{array} \right.$$

En ambos grupos los pesos de los recién nacidos provienen de sendas distribuciones normales de medias desconocidas, y con varianzas que si bien son desconocidas, podemos suponer que son las mismas. Calcular en cuanto influye el que la madre sea fumadora en el peso de su hijo.

Solución: Si queremos estimar en cuanto influye el que la madre sea fumadora en el peso de su hijo, podemos estimar un intervalo de confianza para $\mu_1 - \mu_2$, lo que nos dará la diferencia de peso esperado entre un niño del primer grupo y otro del segundo. El estadístico que se ha de aplicar para esta cuestión es:

$$\frac{(\bar{x}_1 - \bar{x}_2) - (\mu_1 - \mu_2)}{\hat{S} \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \sim t_{n_1+n_2-2} = t_{35+27-2} = t_{60}$$

donde

$$\hat{S}^2 = \frac{(n_1 - 1)\hat{S}_1^2 + (n_2 - 1)\hat{S}_2^2}{n_1 + n_2 - 2} = \frac{34 \cdot 0,5^2 + 26 \cdot 0,8^2}{60} = 0,419 \Rightarrow \hat{S} = 0,6473$$


Consideramos un nivel de significación que nos parezca aceptable, por ejemplo $\alpha = 0.05$, y el intervalo buscado se obtiene a partir de

$$\frac{\overbrace{|(3,6 - 3,2) - (\mu_1 - \mu_2)|}^{0,4}}{\underbrace{0,6473 \sqrt{\frac{1}{35} + \frac{1}{27}}}_{0,1658}} \leq t_{60; 1-0,05/2} = t_{60; 0,975} = 2$$

$$\Rightarrow \mu_1 - \mu_2 = 0,4 \pm 2 \cdot 0,1658 \Rightarrow \mu_1 - \mu_2 = 0,4 \pm 0,3316_{95\%}$$

Con lo cual se puede decir que un intervalo de confianza para el peso esperado en que supera un hijo de madre no fumadora al de otro de madre fumadora está comprendido con un nivel de confianza del 95% entre los 0,068 Kg y los 0,731 Kg.

- b) Intervalo para la diferencia de medias no homocedáticas (varianzas diferentes): No se verá en este módulo, se recomienda profundizar en otra bibliografía



2.3) CONTRASTES DE DIFERENCIA ENTRE MEDIAS POBLACIONALES INDEPENDIENTES

Este tipo de contraste también es aplicado para diferencia de medias, pero en los casos en los que se comparan medias poblacionales para un carácter determinado en dos poblaciones distintas. Sean dos poblaciones normales $N(\mu_x, \sigma_x)$ y $N(\mu_y, \sigma_y)$ con σ_x y σ_y conocidas, de las cuales se extraen dos muestras aleatorias e independientes de tamaño n_x y n_y respectivamente. Con un nivel de significación α dado, queremos realizar los siguientes contrastes:

$$1. \begin{cases} H_0 : \mu_x - \mu_y = d_0 \\ H_1 : \mu_x - \mu_y \neq d_0 \end{cases} \quad 2. \begin{cases} H_0 : \mu_x - \mu_y \leq d_0 \\ H_1 : \mu_x - \mu_y > d_0 \end{cases} \quad \text{o} \quad 3. \begin{cases} H_0 : \mu_x - \mu_y \geq d_0 \\ H_1 : \mu_x - \mu_y < d_0 \end{cases}$$

El caso más frecuente es cuando $d_0=0$. Sin embargo, es posible probar la hipótesis de que la diferencia es igual que, mayor o igual que, menor o igual que algún valor distinto de cero.

Utilizando el estadístico $z_{\text{exp}} = \frac{\bar{x} - \bar{y} - d_0}{\sqrt{\frac{\sigma_x^2}{n_x} + \frac{\sigma_y^2}{n_y}}}$ se tienen los siguientes contrastes.

Contraste de medias con varianzas conocidas:

De manera similar al caso del contraste para una media, queremos en esta ocasión contrastar la hipótesis de que las dos poblaciones (cuyas varianzas suponemos conocidas) sólo difieren en una cantidad Δ

$$H_0 : \mu_1 - \mu_2 = \Delta$$

frente a hipótesis alternativas que darán lugar a contrastes unilaterales o bilaterales. Para ello nos basamos en la distribución del siguiente estadístico de contraste:

$$\begin{aligned} H_0 \text{ cierta} &\Rightarrow \begin{cases} \bar{X}_1 \sim N\left(\mu_1, \frac{\sigma_1^2}{n_1}\right) \\ \bar{X}_2 \sim N\left(\mu_2, \frac{\sigma_2^2}{n_2}\right) \end{cases} \\ &\Rightarrow \bar{X}_1 - \bar{X}_2 \sim N\left(\Delta, \frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}\right) \\ &\Leftrightarrow \boxed{Z = \frac{(\bar{X}_1 - \bar{X}_2) - \Delta}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \sim N(0, 1)} \end{aligned}$$

1. Contraste bilateral o de dos colas:

$$\begin{cases} H_0 : \mu_1 - \mu_2 = \Delta \\ H_1 : \mu_1 - \mu_2 \neq \Delta \end{cases} \quad Z_{exp} = \frac{(\bar{X}_1 - \bar{X}_2) - \Delta}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}}$$

$$Z_{teo} = z_{1-\alpha/2}$$

Se define entonces :

$$\text{Se acepta } H_0 \text{ si: } -z_{\alpha/2} \leq z_{exp} \leq z_{\alpha/2}$$

y el test consiste en:

$$\begin{cases} \text{si } |Z_{exp}| \leq Z_{teo} \implies \text{no rechazamos } H_0; \\ \text{si } |Z_{exp}| > Z_{teo} \implies \text{rechazamos } H_0 \text{ y aceptamos } H_1. \end{cases}$$

2. Contrastes unilaterales o de una cola

Se utiliza en ambos caso el mismo estadístico utilizado para el contraste bilateral:

$$Z_{exp} = \frac{(\bar{X}_1 - \bar{X}_2) - \Delta}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}}$$

$$Z_{teo} = z_{1-\alpha/2}$$

Para el test

$$\begin{cases} H_0 : \mu_1 - \mu_2 = \Delta \\ H_1 : \mu_1 - \mu_2 < \Delta \end{cases} \quad \left(\text{o bien } \begin{cases} H_0 : \mu_1 - \mu_2 \geq \Delta \\ H_1 : \mu_1 - \mu_2 < \Delta \end{cases} \right)$$

$$\text{Se acepta } H_0 \text{ si: } z_{exp} > -z_{\alpha}$$

$$Z_{teo} = z_{\alpha} = -z_{1-\alpha} \rightarrow \begin{cases} \text{si } Z_{exp} \geq Z_{teo} \implies \text{no rechazamos } H_0; \\ \text{si } Z_{exp} < Z_{teo} \implies \text{rechazamos } H_0 \text{ y aceptamos } H_1. \end{cases}$$

y para el contraste de significación contrario:

$$\begin{cases} H_0 : \mu_1 - \mu_2 = \Delta \\ H_1 : \mu_1 - \mu_2 > \Delta \end{cases} \quad \left(\text{o bien } \begin{cases} H_0 : \mu_1 - \mu_2 \leq \Delta \\ H_1 : \mu_1 - \mu_2 > \Delta \end{cases} \right)$$

$$\text{Se acepta } H_0 \text{ si: } z_{exp} \leq z_{\alpha}$$

$$Z_{teo} = z_{1-\alpha} \rightarrow \begin{cases} \text{si } Z_{exp} \leq Z_{teo} \Rightarrow & \text{no rechazamos } H_0; \\ \text{si } Z_{exp} > Z_{teo} \Rightarrow & \text{rechazamos } H_0 \text{ y aceptamos } H_1. \end{cases}$$

Ejemplo: Un equipo de investigadores desea saber si los datos que han recolectado proporcionan la evidencia suficiente para indicar una diferencia entre las concentraciones medias de ácido úrico en el suero de individuos normales e individuos con síndrome de Down. Los datos presentan las concentraciones de ácido úrico en el suero de 12 individuos con síndrome de Down y 15 individuos sanos. Las medias son $\bar{x}_1=4.5\text{mg}/100\text{ml}$ y $\bar{x}_2=3.4\text{mg}/100\text{ml}$.

Solución: El contraste es $H_0: \mu_1 - \mu_2 = 0$ o $\mu_1 = \mu_2$
 $H_1: \mu_1 - \mu_2 \neq 0$ o $\mu_1 \neq \mu_2$

Si $\alpha=0.05$, los valores críticos de z son ± 1.96 . Se rechaza H_0 a menos que $-1.96 < z_{calculada} < 1.96$.

Cálculo de la estadística de prueba:

$$Z = \frac{(4.5 - 3.4) - 0}{\sqrt{1/12 + 1/15}} = \frac{1.1}{0.39} = 2.82$$

Como 2.82 es mayor que 1.96 se rechaza la hipótesis nula. Se concluye que, de acuerdo con estos datos, hay indicios de que las medias de las poblaciones son diferentes.

a) Contraste de medias homocedáticas

Aplicable al caso en el que deseamos contrastar la diferencia de medias de dos poblaciones independientes cuando sólo conocemos que las varianzas de ambas poblaciones son iguales, pero desconocidas. El problema a contrastar es:

$$H_0 : \mu_1 - \mu_2 = \Delta$$

El estadístico que usaremos para el contraste ya lo hemos visto. Si suponemos que H_0 es cierta se tiene

$$T_{exp} = \frac{(\bar{X}_1 - \bar{X}_2) - (\mu_1 - \mu_2)}{\hat{S} \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \rightsquigarrow t_{n_1+n_2-2}$$

Donde $\hat{S}^2$ es la cuasivarianza muestral ponderada de $\hat{S}_1^2$ y $\hat{S}_2^2$.

$$\hat{S}^2 = \frac{(n_1 - 1)\hat{S}_1^2 + (n_2 - 1)\hat{S}_2^2}{n_1 + n_2 - 2}$$

Se han perdido dos grados de libertad a causa de la estimación de $\sigma_1^2 = \sigma_2^2$ mediante $\hat{S}_1^2$ y $\hat{S}_2^2$.

1. Contraste bilateral

$$\text{Para el contraste de significación : } \begin{cases} H_0 : \mu_1 - \mu_2 = \Delta \\ H_1 : \mu_1 - \mu_2 \neq \Delta \end{cases}$$

Se tiene como en casos anteriores que el contraste adecuado consiste en definir

$$T_{exp} = \frac{(\bar{X}_1 - \bar{X}_2) - (\mu_1 - \mu_2)}{\hat{S} \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}}$$

$$T_{teo} = t_{n_1+n_2-2, 1-\alpha/2}$$

Y rechazar o admitir la hipótesis nula siguiendo el criterio

$$\begin{cases} \text{si } |T_{exp}| \leq T_{teo} \implies \text{no rechazamos } H_0; \\ \text{si } |T_{exp}| > T_{teo} \implies \text{rechazamos } H_0 \text{ y aceptamos } H_1. \end{cases}$$

2. Contrastes unilaterales

Cuando el contraste es unilateral del modo

$$\begin{cases} H_0 : \mu_1 - \mu_2 = \Delta \\ H_1 : \mu_1 - \mu_2 < \Delta \end{cases} \quad \left(\text{o bien } \begin{cases} H_0 : \mu_1 - \mu_2 \geq \Delta \\ H_1 : \mu_1 - \mu_2 < \Delta \end{cases} \right)$$

El contraste se realiza siguiendo el mismo proceso que en otros realizados anteriormente y utilizando el mismo estadístico, lo que nos lleva a

$$T_{teo} = -t_{n_1+n_2-2, 1-\alpha} \rightarrow \begin{cases} \text{si } T_{exp} \geq T_{teo} \implies \text{no rechazamos } H_0; \\ \text{si } T_{exp} < T_{teo} \implies \text{rechazamos } H_0 \text{ y aceptamos } H_1. \end{cases}$$

Y cuando el contraste de significación es el contrario

$$\begin{cases} H_0 : \mu_1 - \mu_2 = \Delta \\ H_1 : \mu_1 - \mu_2 > \Delta \end{cases} \quad \left(\text{o bien } \begin{cases} H_0 : \mu_1 - \mu_2 \leq \Delta \\ H_1 : \mu_1 - \mu_2 > \Delta \end{cases} \right)$$

Del mismo modo

$$T_{teo} = t_{n_1+n_2-2, 1-\alpha} \rightarrow \begin{cases} \text{si } T_{exp} \leq T_{teo} \Rightarrow \text{no rechazamos } H_0; \\ \text{si } T_{exp} > T_{teo} \Rightarrow \text{rechazamos } H_0 \text{ y aceptamos } H_1. \end{cases}$$

Ejemplo: Un grupo de investigadores colecta datos acerca de las concentraciones de amilasa en el suero de muestras de individuos sanos y de individuos hospitalizados. Desean saber si es posible concluir que las medias de las poblaciones son distintas. Los datos son las mediciones de amilasa en suero de $n_2 = 15$ individuos sanos y $n_1 = 22$ individuos hospitalizados. Las medias muestrales y sus desviaciones estándar son las siguientes:

$$\begin{array}{ll} \bar{x}_1 = 120 \text{ unidades/ml} & s_1 = 40 \text{ unidades/ml} \\ \bar{x}_2 = 96 \text{ unidades/ml} & s_2 = 35 \text{ unidades/ml} \end{array}$$

Solución: El contraste es: $H_0: \mu_1 - \mu_2 = 0$

$$H_1: \mu_1 - \mu_2 \neq 0$$

Si definimos a $\alpha = 0.05$, los valores críticos de t son ± 2.0301 . Se rechaza H_0 a menos que $-2.0301 < t_{calculada} < 2.0301$.

El cálculo de la estadística de prueba es:

$$\hat{s}^2 = \frac{21(1600) + 14(1225)}{21 + 14} = 1450$$

$$t = \frac{(120 - 96) - 0}{\sqrt{\frac{1450}{15} + \frac{1450}{22}}} = \frac{24}{12.75} = 1.88$$

No es posible rechazar H_0 porque $-2.0301 < 1.88 < 2.0301$. Es decir, 1.88 cae dentro de la región de aceptación. Con base a estos datos no es posible concluir que las dos medias de la población son diferentes.

b) Contraste de medias no homocedáticas : (no se verá en este material)

Distribución Muestral de Diferencia de Proporciones

Muchas aplicaciones involucran poblaciones de datos cualitativos que deben compararse utilizando proporciones o porcentajes.

Quando el muestreo procede de dos poblaciones binomiales y se trabaja con dos proporciones muestrales, la distribución muestral de diferencia de proporciones es aproximadamente normal para tamaños de muestra grande ($n_1 p_1 \geq 5$, $n_1 q_1 \geq 5$, $n_2 p_2 \geq 5$ y $n_2 q_2 \geq 5$). Entonces p_1 y p_2 tienen distribuciones muestrales aproximadamente normales, así que su diferencia $p_1 - p_2$ también tiene una distribución muestral aproximadamente normal.

Cuando se estudió la distribución muestral de proporciones se comprobó que $\mu_{\hat{p}} = p$ y que $\sigma_{\hat{p}} = \sqrt{\frac{pq}{n}}$ por lo que se puede deducir que:

$$\mu_{\hat{p}_1 - \hat{p}_2} = p_1 - p_2 \text{ y que } \sigma_{\hat{p}_1 - \hat{p}_2} = \sqrt{\frac{P_1 q_1}{n_1} + \frac{P_2 q_2}{n_2}}.$$

Si tenemos dos poblaciones suficientemente pequeñas, podemos extraer de la población 1 todas las muestras aleatorias posibles de tamaño n_1 y calcular a partir de cada conjunto de datos de la muestra la proporción de la muestra $\hat{p}_1$. Lo mismo podemos hacer con la población 2. Luego es posible calcular las diferencias entre todos los pares posibles de proporciones muestrales, donde un miembro de cada par tiene un valor $\hat{p}_1$ y el otro un valor $\hat{p}_2$. La distribución muestral de la diferencia entre las dos porciones de las muestras consiste en todas las diferencias existentes acompañadas de sus frecuencias de ocurrencias. La fórmula que se utilizará para el cálculo de probabilidad del estadístico de diferencia de proporciones es:


$$z = \frac{(p_1 - p_2) - (P_1 - P_2)}{\sqrt{\frac{P_1 q_1}{n_1} + \frac{P_2 q_2}{n_2}}}$$

Ejemplo: Los hombres y mujeres adultos de una ciudad grande en sus opiniones sobre la promulgación de la pena de muerte para personas culpables de asesinato. Se cree que el 12% de los hombres adultos están a favor de la pena de muerte, mientras que sólo 10% de las mujeres adultas lo están. Si se pregunta a dos muestras aleatorias de 100 hombres y 100 mujeres su opinión sobre la promulgación de la pena de muerte, determine la probabilidad de que el porcentaje de hombres a favor sea al menos 3% mayor que el de las mujeres.

Solución: Datos: $P_H = 0.12$, $P_M = 0.10$, $n_H = 100$, $n_M = 100$ y $p(p_H - p_M \geq 0.03) = ?$

Hay que tener en cuenta que debe incluirse el factor de corrección de 0.5 por ser una distribución binomial y que se está utilizando la distribución normal.

$$z = \frac{(p_H - p_M) - (P_H - P_M)}{\sqrt{\frac{P_H q_H}{n_H} + \frac{P_M q_M}{n_M}}} = \frac{0.025 - (0.12 - 0.10)}{\sqrt{\frac{(0.12)(0.88)}{100} + \frac{(0.10)(0.90)}{100}}} = 0.11$$



Se concluye que la probabilidad de que el porcentaje de hombres a favor de la pena de muerte, al menos 3% mayor que el de mujeres es de 0.4562.

Estimación de la Diferencia de dos Proporciones

Muchas veces se tiene interés en conocer la magnitud de la diferencia entre dos poblaciones, podemos comparar por ejemplo, entre hombres y mujeres, dos grupos de edades, dos grupos socioeconómicos.

Un estimador puntual insesgado de la diferencia de proporciones de las poblaciones se obtiene al calcular las diferencias de las proporciones de las muestras $\hat{p}_1 - \hat{p}_2$. Cuando n_1 y n_2 son de gran tamaño y las proporciones de la población no están muy cerca de 0 o de 1, es posible aplicar el teorema del límite central y utilizar la teoría de la distribución normal para obtener los intervalos de confianza.

Vamos a considerar que tenemos dos poblaciones de modo que en cada una de ellas estudiamos una [v.a. dicotómica \(Bernoulli\)](#) de parámetros respectivos p_1 y p_2 . De cada población vamos a extraer muestras de tamaño n_1 y n_2

Si las muestras son suficientemente grandes ocurre que

$$\hat{p}_1 - \hat{p}_2 = \frac{X_1}{n_1} - \frac{X_2}{n_2} \approx N \left(p_1 - p_2, \frac{p_1 q_1}{n_1} + \frac{p_2 q_2}{n_2} \right)$$

Anteriormente, se vio el tema de la generación de las distribuciones muestrales, en donde se tenía el valor de los parámetros, se seleccionaban dos muestras y podíamos calcular la probabilidad del comportamiento de los estadísticos. Para este caso en particular se utilizará la distribución muestral de diferencia de proporciones para la estimación de la misma. Recordando la formula:

$$z = \frac{(p_1 - p_2) - (P_1 - P_2)}{\sqrt{\frac{P_1 q_1}{n_1} + \frac{P_2 q_2}{n_2}}}$$

Despejando $P_1 - P_2$ de esta ecuación obtenemos un intervalo de confianza del $100(1 - \alpha)$ para $P_1 - P_2$:

$$P_1 - P_2 = (p_1 - p_2) \pm z \sqrt{\frac{P_1 q_1}{n_1} + \frac{P_2 q_2}{n_2}}$$

Donde Z se obtiene de la tabla de distribución normal al nivel $1-\alpha/2$.

Aquí se tiene el mismo caso que en la estimación de una proporción, ya que al hacer el despeje nos queda las dos proporciones poblacionales y es precisamente lo que queremos estimar, por lo que se utilizarán las proporciones de la muestra como estimadores puntuales:

Ejemplo: Un artículo relacionado con la salud, reporta los siguientes datos sobre la incidencia de disfunciones importantes entre recién nacidos con madres fumadoras de marihuana y de madres que no la fumaban:

	Usaria	No Usaria
Tamaño Muestral	1246	11178
Número de disfunciones	42	294
Proporción muestral	0.0337	0.0263

Encuentre el intervalo de confianza del 99% para la diferencia de proporciones.

Solución: Representemos P_1 la proporción de nacimientos donde aparecen disfunciones entre todas las madres que fuman marihuana y definamos P_2 , de manera similar, para las no fumadoras. El valor de z para un 99% de confianza es de 2.58.

$$\begin{aligned} P_1 - P_2 &= (p_1 - p_2) \pm z \sqrt{\frac{p_1 q_1}{n_1} + \frac{p_2 q_2}{n_2}} = \\ &= (0.0337 - 0.0263) \pm 2.58 \sqrt{\frac{(0.0337)(0.9663)}{1246} + \frac{(0.0263)(0.9737)}{11178}} \end{aligned}$$

$$IC(P; 99\%) = [-0.0064 < P_1 - P_2 < 0.0212]$$

Este intervalo es bastante angosto, lo cual sugiere que $P_1 - P_2$ ha sido estimado de manera precisa. Por otra parte al tener el valor 0 podemos deducir que las proporciones no tendrían una diferencia significativa. Con el contraste podemos demostrar esta consideración.

Contrastes sobre la diferencia de proporciones

Supongamos que tenemos dos muestras independientes tomadas sobre dos poblaciones, en la que estudiamos una variable de tipo dicotómico (Bernoulli):

$$\begin{aligned} \vec{X}_1 &\equiv X_{11}, X_{12}, \dots, X_{1n_1} \\ \vec{X}_2 &\equiv X_{21}, X_{22}, \dots, X_{2n_2} \end{aligned}$$

Si X_1 y X_2 contabilizan en cada caso el número de éxitos en cada muestra se tiene que cada una de ellas se distribuye como una variable aleatoria binomial, de modo que los estimadores de las proporciones en cada población tienen distribuciones que de un modo aproximado son normales (cuando n_1 y n_2 son bastante grandes)

$$\hat{P}_1 = \frac{X_1}{n_1} \approx \mathbf{N}\left(p_1, \frac{p_1 q_1}{n_1}\right)$$
$$\hat{P}_2 = \frac{X_2}{n_2} \approx \mathbf{N}\left(p_2, \frac{p_2 q_2}{n_2}\right)$$

El contraste que nos interesa realizar es el de si la diferencia entre las proporciones en cada población es una cantidad conocida Δ

$$H_0 : p_1 - p_2 = \Delta$$

Si H_0 fuese cierta se tendría que:

$$\hat{P}_1 - \hat{P}_2 \approx \mathbf{N}\left(\underbrace{p_1 - p_2}_{\Delta}, \frac{p_1 q_1}{n_1} + \frac{p_2 q_2}{n_2}\right)$$

Desafortunadamente ni p_1 ni p_2 son conocidos de antemano y utilizamos sus estimadores, lo que da lugar a un error que es pequeño cuando los tamaños muestrales son importantes:

$$\boxed{\frac{(\hat{p}_1 - \hat{p}_2) - \Delta}{\sqrt{\frac{\hat{p}_1 \hat{q}_1}{n_1} + \frac{\hat{p}_2 \hat{q}_2}{n_2}}} = Z_{exp} \approx \mathbf{N}(0, 1)}$$

La prueba que se utiliza con más frecuencia con relación a la diferencia entre las proporciones de dos poblaciones es aquella en la que su diferencia es cero. Sin embargo, es posible probar que dicha diferencia es igual a algún otro valor. Se pueden hacer pruebas unilaterales y bilaterales.

Siempre que la hipótesis nula sea $p_1 - p_2 = 0$, se supone que las proporciones de las dos poblaciones son iguales. Esto permite combinar los resultados de las dos muestras y obtener una estimación ponderada de la proporción común supuesta:

$$\bar{p} = x_1 + x_2 / n_1 + n_2$$

Donde x_1 y x_2 son el número de la primera y segunda muestra que poseen la característica de interés. Esta estimación ponderada se utiliza para calcular el error estándar estimado para el estimador como sigue:

$$\hat{\sigma} = \sqrt{\frac{p(1-p)}{n} + \frac{p(1-p)}{n}}$$

Ejemplo: En un estudio para comparar un nuevo tratamiento para la migraña con el tratamiento habitual, 78 de los 100 individuos que recibieron el tratamiento habitual respondieron favorablemente. De los 100 individuos que recibieron el nuevo tratamiento, 90 respondieron satisfactoriamente. ¿Proporcionan estos datos la evidencia suficiente para afirmar que el nuevo tratamiento es más efectivo que el habitual?

Solución: Se calculan: $\hat{p}_1 = 78/100 = 0.78$ $\hat{p}_2 = 90/100 = 0.90$

$$p = \frac{90 + 78}{100 + 100} = 0.84$$

Las hipótesis son: $H_0 = p_2 - p_1 \leq 0$

$$H_1 = p_2 - p_1 > 0$$

Sea $\alpha = 0.05$. El valor crítico de z es 1.645. Se rechaza H_0 si el valor de z es mayor que 1.645.

El cálculo del estadístico de prueba es:

$$z = \frac{(0.90 - 0.78)}{\sqrt{\frac{(0.84)(0.16)}{100} + \frac{(0.84)(0.16)}{100}}} = \frac{0.12}{0.0518} = 2.32$$

Como $2.32 > 1.645$, se rechaza H_0 . Estos datos sugieren que el tratamiento es más efectivo que el habitual

PREGUNTAS CLAVES DEL TEMA 1B RESPONDER (MUY IMPORTANTE)

Basado solo en este material luego de la lectura de estudio responder a las siguientes preguntas que se indicará donde hay que subirlas (SE INVIARÁ UN LINK DE CARGA):

- 1) Si quiero comparar las poblaciones ¿qué parámetros puedo utilizar y cuáles son sus correspondientes estimadores?
- 2) ¿Cómo debe ser el muestreo, cual es el principal y cuales otros se menciona ?
- 3) ¿Qué debemos estudiar de los estimadores y cuáles son los pasos obligados de la estadística inferencial?
- 4) Menciona las diferentes opciones que existe para calcular la diferencia de medias según cada situación planteada en el problema y los datos.
- 5) Presentar simbólicamente las distribuciones en el muestreo de los estimadores diferencia de las medias (muestra chicas y desvío desconocido) y el de diferencia de proporciones poblacionales.
- 6) Presentar las fórmulas más relevantes del capítulo (errores estándar, intervalos de confianza y estadísticos de prueba).